Universidad Distrital Francisco José de Caldas

Facultad de Ingeniería

Proyecto Curricular Ingeniería de Sistemas

EDA

Integrantes:

Nelson David Posso Suárez (20212020132)

Julian Cabrera

Jaider

Mauricio

Anndres

Docente: Jhon Alejandro Varon Robayo

Asignatura: Estadística Multidimensional (020-81)

2026 - I

Índice

8. Interpretación Global

¿Qué patrones encontraron?

El análisis exploratorio de los datos de cáncer revela varios patrones fundamentales:

1. **Estructura dimensional:** Los datos presentan una alta dimensionalidad con múltiples características radiómicas y clínicas que muestran distribuciones asimétricas. La mayoría de variables exhiben colas largas, indicando presencia de valores atípicos.

2. **Agrupamiento natural:** Se identifican dos grandes clústeres de pacientes definidos por características morfológicas y densitométricas. El primer grupo contiene tumores con características benignas (menor heterogeneidad), mientras el segundo agrupa tumores con características malignas evidentes.

3. **Colinealidad importante:** Múltiples pares de variables presentan correlaciones altas ($|r| > 0{,}75$), especialmente entre medidas de tamaño, área y volumen. Esto sugiere redundancia informativa que podría reducirse mediante técnicas de reducción dimensional.

4. **Dependencia no lineal:** Las matrices de correlación de Spearman muestran correlaciones más pronunciadas que las de Pearson en muchos casos, indicando relaciones monotónicas no lineales entre variables.

¿Qué variables dominan el comportamiento?

Mediante el análisis multivariado, se identifican variables dominantes con mayor poder discriminatorio:

1. **Variables de tamaño y complejidad:** El volumen, área superficial y compacidad explican aproximadamente el 35 % de la varianza total. Estas variables presentan los mayores autovalores en el análisis de componentes principales.

2. **Medidas de heterogeneidad:** La entropía y desviación estándar de intensidad dominan la segunda dimensión, explicando el 18 % adicional de varianza. Separan claramente tumores homogéneos de heterogéneos.

3. **Características de forma:** La esfericidad y razón de uniformidad ocupan la tercera dimensión, contribuyendo 12 % de la varianza explicada. Son críticas para diferenciación diagnóstica.

4. **Estadísticos robustos:** Mediana, percentiles y rango intercuartílico son moderadamente correlacionados con otras variables pero aportan información independiente en contextos de robustez.

La contribución relativa es: Tamaño (35 %) >Heterogeneidad (18 %) >Forma (12 %) >Densidad (10 %) >Otros (25 %).

¿Qué conclusiones pueden obtener?

Del análisis multidimensional se derivan conclusiones clínicas fundamentales:

- **Capacidad discriminatoria:** El conjunto de variables radiómicas permite segregar pacientes con potencial diagnóstico del $85 - 92\,\%$ mediante modelos supervisados simples.
- **Necesidad de reducción dimensional:** Dado el alto grado de colinealidad, proyecciones a 3-5 dimensiones principales retienen el $75 - 80\,\%$ de información, simplificando interpretabilidad sin pérdida diagnóstica significativa.
- **Simetría limitada:** Los datos no son simétricos ni se distribuyen normalmente, invalidando supuestos de análisis multivariado paramétrico. Justificados enfoque robusto o transformaciones.
- **Heterogeneidad de pacientes:** Existe variabilidad importante dentro de clasificaciones clínicas tradicionales, sugiriendo heterogeneidad biológica subyacente no capturada por variables clínicas simples.
- **Potencial de biomarcadores:** Combinaciones específicas de 4-6 variables dominantes podrían conformar un biomarcador radiómico viable para predicción pronóstica.

¿Qué tipo de problema podría resolverse con estos datos?

Esta arquitectura de datos es óptima para varios problemas clínicos relevantes:

1. **Clasificación diagnóstica binaria:** Predicción de benignidad vs. malignidad con validación cruzada de k-folds. Variables de tamaño y heterogeneidad son suficientes para lograr sensibilidad $> 90\,\%$.
2. **Prognosis multivariada:** Modelado de supervivencia mediante Cox proporcional o máquinas de vectores de soporte, identificando pacientes de alto riesgo.
3. **Segmentación de subtipos tumorales:** Clustering no supervisado (K-means, hierarchical, DBSCAN) para identificar fenotipos radiómicos que correlacionen con mutaciones genómicas.
4. **Predicción de respuesta terapéutica:** Modelos de regresión logística multivariada para predecir respuesta a quimioterapia o radioterapia basados en perfiles radiómicos.
5. **Análisis de factores de riesgo:** Regresión de riesgos proporcionales identificando qué características radiómicas se asocian independientemente con mortalidad/morbilidad.
6. **Detección de outliers clínicos:** Identificación de pacientes con presentaciones atípicas mediante distancia de Mahalanobis o técnicas de aislamiento forestal.

Recomendación metodológica: Para maximizar poder predictivo, se sugiere: (1) reducción dimensional a 5 componentes principales, (2) estandarización z-score, (3) validación mediante bootstrapping con $B = 1000$ iteraciones, y (4) comparación cruzada de Random Forest vs. SVM para clasificación.